

Gymnázium J. K. Tyla



Agentické inženýrství ve vývoji softwaru

Návrh a implementace DarkFactory

ODBORNÁ PRÁCE

Autor práce: Patrik Marius, 4.D

Vedoucí práce: Michal Dočekal

Prohlášení

Prohlašuji, že jsem tuto studentskou odbornou práci vypracoval samostatně pod dohledem vedoucího uvedeného na první straně. Všechny použité zdroje jsou uvedeny v seznamu zdrojů a informace z nich získané jsou v textu řádně označeny odkazem na zdroj. Souhlasím s tím, aby tištěná forma práce byla uchována na Gymnáziu J. K. Tyla a tam používána jako tištěný zdroj např. pro další studentské práce či pro prezentaci vzdělávání na GJKT.

V Hradci Králové dne

Podpis autora práce:

.....

Anotace

STUB

Klíčová slova: coding agents; software factory; AI; Agentic Engineering; harness

Abstract

STUB

Keywords: coding agents; software factory; AI; Agentic Engineering; harness

Obsah

Prohlášení	2
1 Úvod	5
1.1 Motivace: Vývoj a adopce generativní AI	5
1.2 Cíl, výzkumná otázka, hypotéza a vymezení	8
1.3 Terminologie	8
2 Teoretická část	9
2.1 Agent: Co to je a jak funguje	9
2.1.1 Jazykový model (LLM)	9
2.1.2 Smyčka (Loop)	10
2.1.3 Nástroje (Tools)	11
2.1.4 Kontext (Context)	12
2.2 Agentické inženýrství	13
2.2.1 Specifikace (Specification)	13
2.2.2 Orchestrace (Orchestration)	15
2.3 Softwareová továrna	18
3 Praktická část	20
3.1 Metodika	20
3.2 Architektura produkčního běhu	21
3.3 Interpretace a plánování požadavku	23
3.4 Implementace a automatická revize	25
3.5 Zpětná vazba, schválení a úklid	26
4 Zjištění a diskuse	27
5 Závěr	28
Seznam zdrojů	29
Seznam součástí textu	33

1 Úvod

1.1 Motivace: Vývoj a adopce generativní AI

Nástroje založené na jazykových modelech prošli v krátké době velkým rozvojem. Nejprve doplňovaly kód v editoru (1).

A screenshot of a code editor interface. At the top, it says 'JS test.js 1' with a small circle icon. Below that, a prompt 'JS test.js > calculateDaysBetweenDates' is shown. The main area displays a JavaScript function definition: '1 function calculateDaysBetweenDates(begin, end) {' followed by four indented lines: 'var beginDate = new Date(begin);', 'var endDate = new Date(end);', 'var days = Math.round((endDate - beginDate) / (1000 * 60 * 60 * 24));', and 'return days;'. The function is closed with a closing brace '}' on line 2. The cursor is positioned at the end of the opening brace on line 1.

Obrázek 1: Doplňování kódu přímo v editoru: model navrhuje pokračování řádku, které člověk přijme nebo odmítne (1).

Potom přišly konverzační chatboty (2), v nichž model sestavuje odpověď, ale nástroje mu zpravidla nebyly k dispozici, takže i nadále všechno provedl uživatel.

P

A 59-year-old female comes to your office for routine examination. On a panoramic radiograph, you noticed some incidental findings. Please provide your diagnosis based on the radiograph below.

1. Florid cemento-osseous dysplasia
2. Secondary hyperparathyroidism
3. Fibrous dysplasia
4. Hypercementosis



As an AI language model, I'm unable to directly view or interpret images. However, I can provide you with a brief description of the conditions you mentioned to help you understand them better.

1. Florid cemento-osseous dysplasia: This is a benign condition that affects the jawbones, specifically the cementum and surrounding bone. It typically appears as multiple radiopaque masses in the jawbones and is often asymptomatic.
2. Secondary hyperparathyroidism: This condition occurs due to chronic kidney disease or vitamin D deficiency, leading to abnormal parathyroid gland function. It can result in increased bone resorption and subsequent radiographic changes.
3. Fibrous dysplasia: Fibrous dysplasia is a bone disorder where normal bone is replaced by fibrous tissue. It can present as an incidental finding on radiographs, showing a radiolucent and ground-glass appearance in affected areas.
4. Hypercementosis: Hypercementosis is a condition characterized by excessive deposition of cementum around the roots of teeth. It can appear as a radiopaque enlargement around the roots of affected teeth.

Without visual examination and additional information, it is challenging to provide an accurate diagnosis based solely on a radiograph. It is recommended to consult with a qualified dental or medical professional who can evaluate the patient's clinical history, symptoms, and perform a physical examination to provide an accurate diagnosis.

Obrázek 2: Chatbot odpovídá textem a práci nechává člověku: místo aby snímek posoudil, přizná, že obrázky neumí, a je to uživatel, kdo musí dojít k závěru. Screenshot z bezplatné verze ChatGPT, převzato z (3).

Až třetí stupeň, *agenti* (4; 5; 6), dostal přístup k souborům, příkazům a běhovému prostředí — a tím se poprvé změnilo kdo pracuje.



Obrázek 3: Odhad rozdělení uživatelů generativní AI podle typu (7).

S rozvojem nástrojů roste i jejich adopce. Rozsah veřejného použití samotných agentů je přitom stále úzký. Jeden ze zveřejněných odhadů klade počet uživatelů chatbotů na 28 % populace a pravidelné užití *agentů* na 0,36 % světové populace (7) Obrázek 3. Přesto je zřejmé, že se jedná o technologii, která se rychle šíří a mění způsob práce, proto v této práci chci ukázat, čeho jsou plnohodnotné systémy schopné.

1.2 Cíl, výzkumná otázka, hypotéza a vymezení

Výzkumná otázka práce zní: *Za jakých podmínek agentický systém spolehlivě vykonává inženýrskou práci?* Inženýrskou prací se zde rozumí změna repozitáře, kterou může jiný člověk než její autor přezkoumat a sloučit, aniž by musel agenta na cokoli ptát; v tomto smyslu je měřena schopnost systému a v tomto smyslu je brána člověka nezaměnitelnou.

Práce předpokládá tuto hypotézu:

Praktická autonomie je vlastností návrhu systému, který práci řídí, a nikoli vlastností modelu, který v něm pracuje.

Hypotéza se ověřuje v praktické části a z jejího výsledku práce vychází.

Praktická část popisuje DarkFactory, záměrně minimální produkční pipeline pro AI-asistovaný softwarový vývoj (8). Její běh, brány a uložený stav tvoří harness této práce; jako vykonávací engine používá produkční harnessy, protože to je pro popsanou míru detailu nejjednodušší.

Rozsah práce je záměrně úzký a odpovídá jedné revizi repozitáře: popisuje počáteční implementaci, v níž je agentní smyčka (*Agent Loop*) provedena cizím nástrojem. Její rozsah slouží jako základ, na němž navazuje práce následující.

1.3 Terminologie

Překlad anglických výrazů v této práci sleduje jedno pravidlo. Co anglicky nazývá **agent**, je česky **agentní** — agent, agentní krok, agentní smyčka. Co anglicky nazývá **agentic**, je česky **agentické** — agentický systém, agentické inženýrství. Podstatné jméno **agent** se tedy nepřekládá, protože označuje samotného jednajícího, zatímco přípona **-ic** znamená schopnost jednat, nikoli samotného jednajícího (9). Podle téhož pravidla je *Agent Loop* česky *agentní smyčka*, protože jde o smyčku agenta, a nikoli o vlastnost systému.

2 Teoretická část

2.1 Agent: Co to je a jak funguje

Agent je model plus harness (10): model navrhuje a harness mu dopředuje kontext, nástroje a pravidla, jejichž prostřednictvím se návrh mění v čin. Celý systém tvoří několik vrstev — rozhraní, smyčka agenta, oprávnění, nástroje, uložený stav a prostředí, v němž běží — a model je jen jedna z nich. Spolehlivost agenta proto neurčuje samotný model, ale skladba těch vrstev. Čím jsou modely schopnější, tím menší část práce zbývá pro tuto skladbu a tím víc práce přebírá model.

2.1.1 Jazykový model (LLM)


Současný jazykový model stojí na architektuře **Transformer**, kterou představil Google v roce 2017 v práci „*Attention Is All You Need*“ (11).

Její základem je **attention**: ke každému tokenu se připočítá vážený součet hodnot všech ostatních, takže jeho reprezentace nese informaci z celého kontextu a vzdálenost mezi pozicemi není pevně daná jejich pořadím. Všechny tokeny se vyhodnocují proti sobě najednou, ale náklady rostou s druhou mocninou délky kontextu.

Jazykový model je sám o sobě jen funkce. Na základě toho, co dostane v kontextu, vypočítá rozložení pravděpodobností nad následujícím tokenem a jeden z nich vybere. Mezi voláními si nic nepamatuje, nezná nic mimo text, který mu byl předložen, a nemá přístup k souborům, příkazům ani stavu práce. Všechno, co o zadání ví, je v kontextu, a jindy se to do něj nedostane.

Při **inferenci** tedy model zpracuje obsah kontextového okna a vytváří výstupní tokeny jeden za druhým, přičemž každý nový token se stane součástí kontextu pro další krok. To je celá jeho schopnost: převést kontext na posloupnost tokenů. Stav mezi kroky, nástroje, ukládání výsledků a oprávnění musí přijít zvenčí — a to je právě to, co doplňuje harness.

Vektorové reprezentace, označované jako **embeddingy**, zachycují sémantické vztahy v prostoru vektorů. Známým příkladem je vztah mezi vektory slov král, královna, muž a žena (12). Tento vztah schematicky znázorňuje Obrázek 4.



Obrázek 4: Ilustrace sémantického vztahu mezi vektorovými reprezentacemi slov *král*, *královna*, *muž* a *žena* (12).

2.1.2 Smyčka (Loop)

Základním mechanismem agentického systému je **agentní smyčka**: konkrétní implementace vzoru **ReAct** (*Reasoning and Acting*) (13) v daném harnessu. Jeden cyklus má pět kroků:

- sestavit kontext: systémové pokyny, dosavadní přepis, stav prostředí;
- nechat model odpovědět;
- je-li v odpovědi požadavek na nástroj, provést jej;
- zapsat výsledek nástroje jako pozorování;
- vrátit se na první krok.

Model přitom v každém cyklu nejprve zdůvodní, co udělá, a teprve pak žádá o nástroj (14). Harness akci provede mimo model a výsledek mu vrátí; ten se připojí k přepisu a cyklus běží dál. Smyčka končí teprve tehdy, když model místo požadavku na nástroj vydá závěrečnou odpověď. V prosté posloupnosti promptů by model nemohl poznat, zda předchozí krok uspěl; průběh shrnuje Obrázek 5.



Obrázek 5: Vzor ReAct: myšlenka, akce a pozorování se střídají a každý z nich se připojí do kontextu, takže smyčka pokračuje na tom, co už model viděl. Končí odpovědí místo dalšího požadavku na nástroj (13).

2.1.3 Nástroje (Tools)

Zadání určuje, co má agent udělat; co mu je dovoleno udělat, určuje harness. Jde o dvě roviny, které se dají měnit nezávisle, a odpovídají běžnému výčtu součástí harnessu (10):

- **Nástroje** umožňují agentovi číst a upravovat soubory, vyhledávat nebo spouštět příkazy. Než se nástroj spustí, harness jeho vstup ověří proti předepsanému schématu, takže chybný požadavek se neprovede.
- **Skills** spojují opakovaně použitelné instrukce, skripty a zdroje pro určitý typ úlohy (15).
- **Hooks** reagují na události životního cyklu a mohou před akcí či po ní vynutit kontrolu (16).
- **Model Context Protocol (MCP)** standardizuje napojení externích nástrojů a datových zdrojů prostřednictvím rozhraní klient–server (17).

Každá akce ještě předtím projde oprávněním, které pro ni platí: provést automaticky, zeptat se člověka, nebo zakázat. Ani když model navrhne něco nebezpečného, dostane se to k provedení jen tehdy, když to oprávnění dovolí.

Instrukce pro agenta leží v repozitáři, standardně v souboru **AGENTS.md** (18) (u Anthropic v **CLAUDE.md**). Takový soubor může existovat v několika úrovních — v kořeni projektu,

ve složce i v jednotlivých podadresářích — a harness si načte jen ten, který se týká právě otevřených souborů. Skilly, scripty a hooky leží pod složkou `.agents/`.

2.1.4 Kontext (Context)

Kontextové okno zahrnuje pracovní kontext jednoho volání modelu: instrukce, části repozitáře, historii volání nástrojů i výsledky předchozích kroků. Jeho kapacita sama o sobě nezaručuje, že model všechny podstatné informace správně využije.

Kompakce (*compaction*) po překročení limitu nahradí starší průběh souhrnem rozhodnutí a výsledků (19).

S rostoucí délkou vstupu ale klesá úspěšnost, s jakou model podstatné informace využije (20). Toto zhoršování práce s nahromaděným kontextem se označuje jako **context rot** (19). Paměť agenta se zkazí takto: zastaralé instrukce, které nikdo neupraví, spory mezi soubory na různých úrovních a pravidla, která se posouvají, aniž by je někdo schválil. Kompakce musí přežít sama sebe — když v souhrnu zůstane jen to, co bylo napsáno naposledy, agent ztratí to, na čem stála celá práce.

2.2 Agentické inženýrství

Agentické inženýrství (**Agentic Engineering**) označuje soubor postupů, jimiž se vývoj softwaru pomocí coding agentů stává účinným, kontrolovaným, opakovatelným a škálovatelným (21). Jeho předmětem není samotný agent ani jeho model, ale systém, v němž agent pracuje: zadání, omezení, nástroje, pravidla integrace a odpovědnost člověka. Odtud také jeho popis jako archetypu **agentického inženýra**, jehož přidanou hodnotu už netvoří psaní kódu, ale formulace zadání, řízení agentních běhů a kritické posouzení strojem vytvořených výstupů (22). Mezi hlavní oblasti patří: **Prompt engineering** (23), **Context engineering** (19), **Harness engineering** (24; 25), **Loop Engineering** (26) a **Workflow/Graph Engineering** (27). Cílem je, aby vývojář mohl efektivně a kontrolovaně delegovat dílčí úkoly agentovi, aniž by ztratil přehled o záměru, rozsahu a kvalitě výsledku.

2.2.1 Specifikace (Specification)

Spolehlivé delegování práce začíná explicitním vymezením cíle, rozsahu, omezení a podmínek přijetí. Specifikace popisuje nejen požadovaný výsledek, ale také části systému, které se měnit nemají, a způsob, jakým bude výsledek ověřen. Tento přístup, označovaný jako **spec-first** nebo *spec-driven development*, dává agentovi před implementací měřitelné hranice a člověku podklad pro posouzení výsledku. Přitom jde o postup používaný i v klasickém vývoji softwaru.

V praxi to znamená, že plán nevzniká až během práce agenta, ale před ní: jeho znění se nejprve dohodnou s člověkem, zapíše do souboru a teprve potom se agent pustí do změn.



Obrázek 6: Plán, který model navrhne, než se začne psát kód: seznam kroků podle souborů, které se mění, a otázka, zda se má pokračovat. Znění plánu je tak oddělené od jeho provádění — je to rozhodnutí, které člověk schvaluje nebo odmítne, nikoli popis práce, která už běží. Screenshot z Claude Code, převzato z (28).

Prompt engineering se soustředí na formulaci instrukcí, omezení, příkladů a očekávaného výstupu konkrétního inferenčního kroku (23). **Context engineering** řeší širší a průběžný výběr, uspořádání, obnovování a kompakci informací, které má model v daném kroku k dispozici (19).

2.2.2 Orchestrace (Orchestration)

Více agentů samo o sobě nezaručuje lepší výsledek. Paralelizace přináší užitek jen tehdy, když jsou omezeny vzájemné závislosti a koordinátor dokáže odhalit konflikty, ověřit dílčí výstupy a posoudit sloučený výsledek vůči společným podmínkám přijetí. Orchestrace proto zahrnuje nejen rozdělení práce, ale také správu kontextu, pořadí kroků, sdílený stav a integrační kontroly. Je nezbytná právě pro rozsáhlé úlohy, které se do jednoho kontextového okna nevejdou: spoléhat se tam na kompakci by znamenalo ztratit kontext, na kterém celé zadání stojí, a agent by navíc nebyl schopen pracovat na částech, které na sebe bezprostředně navazují. Čtyři vzorce na to odpovídají:

- **Coordinator/subagent** rozdělí rozsáhlou úlohu na dílčí běhy: koordinátor deleguje podúkoly specializovanému subagentovi s vlastním kontextem a přebírá jeho výsledek, nezávislé podúkoly zpracují paralelní pracovníci.



```
Antigravity CLI 1.0.0
Gemini 3.5 Flash

> can you start 3 subagents to research how to build a data web app? E.g. a UI agent,
  a data agent and a code quality analyst

▸ Thought for 2s, 852 tokens
  Initiating Project Decomposition

● DefineSubagent(Subagent "ui_researcher" defined successfully. It can now be...)
● DefineSubagent(Subagent "data_researcher" defined successfully. It can now ...)
● DefineSubagent(Subagent "code_quality_analyst" defined successfully. It can...)
(ctrl+o to expand)

▸ Thought for 2s, 634 tokens
  Defining Subagents Concurrently

● Agent(ui_researcher: UI/UX Researcher)(Please research and provide a comprehensive
report on building a premium-grade U...)

I have successfully defined and launched 3 specialized subagents to research
different aspects of building a high-quality data web application:

1. UI/UX Researcher ( ui_researcher )
```


Obrázek 7: Rozhraní Google Antigravity CLI, tedy harnessu agenta běžícího v terminálu: koordinátor definuje tři specializované subagenty a spouští je souběžně; každý běží vlastním kontextem (29).

- **Workflow graph** předem určuje závislosti, pořadí a větvení fází (27). Claude Code u dynamických workflow napíše skript, který runtime vykonává na pozadí, takže smyčku, větvení i mezivýsledky drží skript místo kontextu modelu a plán je program, který lze přechíst a znovu spustit (30).

Phases	CodeReview · 16 agents	
✓ Foundation 8/8	✓ cloud:security	claude-codex-pro 47.2k tok · 15 tools · 1m 32s
✓ AcceptanceCriteria 4/4	✓ cloud:database	claude-deepseek-pro 141.9k tok · 59 tools · 7m 14s
✓ CodeReview 16/16	✓ cloud:python	Sonnet 4.6 120.4k tok · 39 tools · 12m 38s
✓ Verify 39/39	✓ cloud:stripe-deep	claude-deepseek-pro 133k tok · 46 tools · 5m 5s
5 Completeness 3/4	✓ cloud:signup-deep	claude-deepseek-pro 127.2k tok · 46 tools · 5m 58s
6 Synthesis	✓ gubbi:security	claude-codex-pro 34.9k tok · 17 tools · 1m 14s
	✓ gubbi:database	claude-deepseek-pro 117.9k tok · 73 tools · 7m 36s
	✓ gubbi:mcp-deep	claude-deepseek-pro 113.1k tok · 48 tools · 7m 12s
	✓ gubbi:extraction-deep (...	claude-deepseek-pro 131.4k tok · 97 tools · 10m 18s
	✓ gubbi:python	Sonnet 4.6 73.1k tok · 27 tools · 5m 19s
	✓ common:deep	claude-deepseek-pro 134.7k tok · 56 tools · 5m 45s
	✓ common:security	claude-codex-pro 21.5k tok · 9 tools · 1m 16s
	✓ testbench:deep	claude-deepseek-pro 103.8k tok · 79 tools · 6m 16s
	✓ infra:devops	claude-codex-pro 67.9k tok · 33 tools · 8m 46s
	✓ infra:security	claude-codex-pro 112.4k tok · 40 tools · 5m 51s
	✓ infra:architecture	claude-deepseek-pro 94k tok · 42 tools · 5m 57s

Obrázek 8: Postup práce dynamického workflow v Claude Code: vlevo fáze plánu se stavem, vpravo rozvinutá fáze *CodeReview* se 16 agenty, u každého model, spotřebované tokeny, počet nástrojů a doba běhu. Screenshot pochází z komunitního příspěvku; rozhraní i jeho chování popisuje dokumentace (30).

- **Goal loop** je nadřazená řídicí smyčka: po dílčím dokončení ReAct smyčky se pozorovaný stav porovná s cílem a podmínkami přijetí a běh skončí, nebo pokračuje další iterací. Vzor pochází z tzv. **Ralph loop**, který v roce 2025 popsal Geoffrey Huntley jako smyčku, jež opakovaně spouští agenta se stejným zadáním a stav si drží v pracovním stromu, nikoli v přepisu konverzace (31). Dnes je to běžná funkce Claude Code i Codexu (26; 32). Zásadní přitom je, že nejde o jediný pokus: agent dostává zpět to, co jeho krok vyrobil, a může podle toho postup změnit. Spolehlivost tu nevzniká z modelu, ale z toho, že se chyba stane součástí dalšího kroku.



Obrázek 9: Cíl, proti němuž agent postupuje, a jeho splnění: po dokončení dílčího kroku se stav porovná s cílem a běh v tomto případě končí, včetně doby, kterou zabral. Screenshot pochází z komunitního příspěvku; funkci popisuje dokumentace (26).

- **human-in-the-loop (HITL)** označuje bod, v němž se automatizovaná smyčka doplní o kontrolní brány vyžadující explicitní lidské rozhodnutí, například schválení specifikace, potvrzení implementačního plánu nebo přijetí výsledného diffu. Vývojář tak může ponechat agentovi ohraničenou implementační práci a současně si zachovat odpovědnost za záměr a integraci.

2.3 Softwareová továrna

Softwareová továrna je systém, který přebírá co největší část práce na softwaru — od zadání přes implementaci až po revizi — a nechává člověka jen tam, kde jeho úsudek nelze nahradit (33). Pojem je o půl století starší než dnešní vlna agentů: poprvé jej použil Robert Bemer v návrhu strojově řízeného výrobního prostředí (34).

Továrna automatizovala jen kroky, jejichž postup byl předem dán. Agent vykoná i krok, jehož postup předem dán není: zadání přeformuluje, plán sestaví, chybu, kterou sám způsobí, opraví a rozhodne, na řadě je další nástroj, nebo ne. Automatizovatelná část se tím posouvá z provádění na úsudek, zatímco člověk zůstává tam, kde byl v každé dosavadní továrně — u určení, co je správné a co smí do výroby vstoupit.

PRAKTICKÁ ČÁST

DarkFactory

3 Praktická část

3.1 Metodika


Praktická část implementuje záměrně jednoduchou produkční pipeline, v níž je vývojovým prostředím přímo GitHub a harness produkční coding agent. Cílem je ukázat, jak lze spojit události GitHubu, automatizované plánování, izolovanou práci v kontejneru a lidskou integraci do jednoho opakovatelného procesu.

Pythonovský runner, o kterém tato část pojednává, byl napsán pomocí těchž produkčních coding agentů, které následně popisuje. Cílem nebyla stavba co nejuccelenějšího systému, ale co nejmenší uzavřená smyčka, na níž lze ukázat, jak se navzájem ovlivňují agent, harness a lidský recenzent. Pozornost je proto soustředěna na tuto interakci a na její členění, nikoli na šíři nabízených funkcí.


Systém bez vlastního stavového serveru, bez databáze a bez trvalého běžícího procesu je na první pohled méně schopný než plnohodnotná platforma. Oproti ní je však reprodukovatelný, dohledatelný a jehož každé rozhodnutí zůstává vidět v issue, commitu nebo průběhu kontroly. Každý nový prvek pipeline byl přidán až poté, co bylo na konkrétní úloze zřejmé, že současná podoba nestačí, takže složitost rostla postupně. Samotná pipeline se stala nástrojem, kterým byla psána i její další část.

3.2 Architektura produkčního běhu

Pro základní průchod nepotřebuje DarkFactory nic, co by muselo běžet trvale na vlastním počítači. Všechno, co pipeline potřebuje, už existuje: GitHub slouží jako rozhraní i jako trvalý stavový systém a každá práce agenta probíhá jako izolovaný běh v GitHub Actions. Členění do vrstev znázorňuje Obrázek 10 a pořadí jednotlivých kroků Obrázek 11.



Obrázek 10: Architektura: GitHub poskytuje události a vývojový stav, GitHub Actions výpočet, Docker odděluje běh a pythonovský runner převádí událost na agentní krok. Produkční harnessy zajišťují model, nástroje a pozorování (8).



Obrázek 11: Průchod požadavku: implementace a plánování jsou odděleny lidskými bránami, implementace probíhá na větvi a review smyčka se opakuje, dokud nálezní nezmizí. Smyčka může skončit i bez verdiktu; zablokuje ji jen vyčerpaná kvóta (8).

Workflow `agent.yml` reaguje na otevření issue, nový komentář, review komentář, `repository_dispatch` nebo ruční spuštění. Podmínka na úrovni jobu ověří, zda je agent pro repozitář povolen, a odfiltruje automatické komentáře, aby vlastní výstup pipeline

nevytvářel nové události. Workflow provede checkout cílového repozitáře, sestaví obraz podle `docker/Dockerfile.agent` a spustí příkaz `dispatch` v kontejneru.

Pythonovský runner není náhradou harnessu. Převádí událost GitHubu na konkrétní agentní krok, zpracovává jeho výstup a vyvolává další událost. Modelové kroky stále provádí harness nad explicitně předaným pracovním stromem (8).

Každý harness je definován deklarativně: binár, způsob, jak se z promptu sestaví příkazová řádka, a způsob přihlášení. Přidání harnessu je tedy změna dat, nikoli kódu (8). V registru je osm harnessů v konfigurovatelném pořadí a obrázek ukazuje čtyři z nich. Harness, jehož binár v obrazu chybí, se přeskočí, takže jeden obraz unese jen podmnožinu nainstalovaných nástrojů.

Přihlašovací údaje se neukládají do repozitáře. GitHub App nebo jiný autorizovaný token se používá pro checkout, issue, pull requesty a push; přihlašovací údaje modelových providerů jsou předány workflow jako GitHub Secrets a následně prostředím kontejneru (8).

3.3 Interpretace a plánování požadavku

Výchozím bodem je issue s formulovaným požadavkem. Požadavek se však nevytváří jako volný text: repozitář nabízí předlohu, která vyžaduje vyplnit několik polí, a právě ta určují, co pipeline dostane.

Pole předlohy issue

Jak to vypadá v issue 727

Verbatim User Request povinné

restore the agent container build from the checked-in
Bun lock owner

Area / Component povinné

area:ci

Request Type povinné

bug

místo vyplnění předlohy — co napsal požadavek 727

Problem — `Dockerfile.agent` kopíruje kořenový `bun.lock`, ale repozitář má jen `harness/bun.lock`; běh agenta tak padá ještě před spuštěním. Viz `### Contract` v issue.

Tabulka 1: Předloha požadavku a nejstarší požadavek projektu, issue 727 z 20. září 2026. Předloha má šest polí, z nichž tři povinná, ale požadavek, který pipeline zpracovala jako první, předlohu nevyplnil: napsal volně, pod nadpisy `Problem` a `Contract`. Runner předává modelu titulek i tělo issue, takže právě to rozhoduje, co se do zadání dostane (8).

Příklad je záměrně malý a měřitelný: rozsah se vejde do jednoho kontextového okna a podmínky dokončení lze přepsat na testy. To nejsou náročky pipeline, ale podmínky, za kterých je nasazení vůbec smysluplné — a právě proto je předloha součástí popisu. Je tu ale i věc, kterou předloha neumí: přijaté akceptační podmínky jsou text, který vstupuje do kontextu, a nikdo je v popsané revizi nepřevádí na spustitelnou kontrolu. Podmínka, kterou nelze spustit, se při prokazování chová stejně jako podmínka, která neplatí.

Runner načte jeho titulek a text, vyžádá si od modelu interpretaci a zapíše výsledek jako komentář. Komentář má oddělovat doslovné shrnutí požadavku, architektonický rozsah a návrh verifikace. Tím se z chatové odpovědi stane zkontrolovatelný návrh, který lze před dalším během přijmout nebo opravit. Na rozdíl od prostého chatu je tu interpretace artefakt, který přežije běh a dá se k němu vrátit.

Po schválení interpretace je workflow spuštěno znovu a runner založí *child* issue s názvem začínajícím na `Plan:`, nativně propojené s původním issue. Model dostane schválený požadavek a sestaví implementační plán s očekávanými změnami, soubory nebo oblastmi repozitáře a kroky ověření. Plán se opět zobrazí v issue a schvaluje se samostatně. Schválení je tak explicitní bránou: samotná schopnost agenta plán vytvořit neznamena oprávnění

měnit kód. Obě brány před vznikem větve jsou lidské, a protože jsou oddělené, lze schválit porozumění zadání a odmítnout plán, který z něj vychází.

Zpětná vazba člověka není součástí nového vývoje od začátku. Komentář se změnou nebo odmítnutím se předá zpět interpretaci nebo plánování, takže se opravuje rozhodnutí před vytvořením pracovní větve. Tento jednoduchý model odděluje porozumění zadání, plánování a vlastní implementaci bez potřeby složitého grafového orchestrátoru (8), což je volba, již literatura připouští jako legitimní: paralelní práce je užitečná tam, kde na sobě úlohy nezávisí, a jinde je to jen zdroj sporu (27).

3.4 Implementace a automatická revize

Po schválení plánu runner vytvoří nebo načte pracovní větev odvozenou z výchozí větve. Implementační instrukce obsahuje schválený plán, omezení na jeho rozsah a pravidla pro testy a dokumentaci. Harness následně může procházet repozitář, upravovat soubory a používat nástroje nad `/workspace`; změny zůstávají izolované mimo výchozí větev.

Po implementaci runner spustí dostupné formátovací nástroje a deklarované testovací sady. Při neúspěchu předá výstup kontroly agentnímu kroku `fix`, který má opravit chybu bez opuštění schváleného rozsahu. Testovací sady se přitom spouštějí pouze jednou a po opravě už ne: kód se zformátuje, zakomituje a odešle dál, i kdyby opravená verze stále neprocházela. Opakovatelná kontrola tedy rozliší dobrý a špatný stav, ale není překážkou — změna s neprocházejícími testy se dostane do draft pull requestu stejně jako změna procházející. Následně runner vytvoří commit, odešle větev a otevře draft pull request, čímž se změna oddělí od svého posouzení: implementace může být dokončena, ale pull request ještě není připraven k merge (8).

Na draft pull requestu začíná automatická review smyčka. Každá iterace načte aktuální větev a diff a předá je modelové revizi, zatímco průběžná integrace znovu spustí tytéž nástroje. Nalezený problém runner zveřejní a spustí nový běh s fází opravy, která změní větev a spustí další review. Nález vyžadující zásah mimo plán se neodmítne: runner jej zapíše jako Plan Deviation s odůvodněním na původním issue a plán tím doplní. Schválený plán tedy není neměnný, ale každá jeho změna je zapsaná a odůvodněná. Smyčka však může skončit bez jakéhokoli verdiktu a bez komentáře, pull request zůstane ve stavu draft a nikdo zvenčí nepozná, zda review prošlo nebo se jen zastavilo. Jediným stavem, který v této revizi znamená zablokování, je vyčerpaná kvóta — tehdy se zapíše kontrolní bod, stav na projektové tabuli a komentář s výzvou k obnovení (8).

Tabulka 1 ukazuje požadavek podaný právě kvůli této meze: žádá, aby se běh po opakováních stejného nálezu *zastavil a napsal to výslovně do issue*. Popsaná revize to neumí, ačkoli je podmínka zastavení v té dokumentaci uvedena výslovně (26).

Po čisté review ještě proběhne kontrola souladu výsledného diffu se schváleným plánem. Ani ta není porovnáním sad souborů: je to druhý dotaz modelu, tentokrát na shodu s textem plánu. Teprve když oba dotazy vyjdou bez nálezu, je draft pull request označen jako připravený k lidské revizi. Je důležité, že automatická revize může skončit bez nálezu, aniž by zaručila, že implementace odpovídá zadání, a posuzuje přitom plán, jehož text napsal tentýž model. Dodavatelé tento typ hodnotitele popisují stejně omezeně (32), a je proto s první branou rovnocenný, ne její náhradou.

3.5 Zpětná vazba, schválení a úklid

Po otevření pro lidskou revizi může člověk použít schvalovací workflow nebo zpětnou vazbu na pull requestu. Změnový požadavek zachycuje runner jako opravný běh na stejné větvi. Agent obdrží plán, konkrétní zpětnou vazbu a aktuální kontext větve, provede úpravu, uloží ji jako commit a znovu spustí automatickou review smyčku. Tím se zpětná vazba nevrací do schváleného plánu ani nevyžaduje nový počátek celého požadavku; zachovává se pouze řetězec revizí na jednom pull requestu (8).

Schválení pull requestu zpracovává samostatný workflow. Ten nejprve ověří, kdo akci provedl, a ověření je užší, než by se z krátkého popisu zdálo: aktér se porovnává s jedním pevně zapsaným účtem, vlastníkem repozitáře. Neověřuje se tedy autor issue ani úroveň oprávnění, ale členství v tomto seznamu (8). Teprve pak workflow převede draft na ready stav, zkontroluje požadované schválení a zapne merge. Přesun na projektovou tabuli dělá osobní přístupový token, protože GitHub přiřazuje práva k Projects v2 jen organizacím; tabule patří uživateli při úspěchu použije `--delete-branch`, takže se pracovní větev po sloučení odstraní. Integrace tedy nekončí pouhým otevřením pull requestu: zahrnuje přechod do ready, splnění ochrany větve, merge a bezpečné odstranění větve (8; 35).

Tato architektura je záměrně jednoduchá. GitHub poskytuje události, schválení, uložení změn a průběh kontroly, GitHub Actions výpočet, Docker odděluje běh, Python koordinuje a harness vykonává agentní práci. Složitější služby, trvalý stavový server a více souběžných agentů jsou záměrně mimo základní návrh. Výhodou je snadná reprodukovatelnost a viditelnost každého rozhodnutí; nevýhodou je zároveň závislost na dostupnosti GitHubu a na kvalitě promptu, modelu a pravidel repozitáře, kterou samotná automatizace neodstraňuje.

Směr vývoje, který práce záměrně nepopisuje, je vymezen v Kapitola 1.2. Zde je tedy přesnější dodat, kde popsán průchod končí: je popsán stav, v němž pythonovský runner volal cizí produkční CLI (8). Popsaná architektura je tudíž mezníkem, nikoli vyvrcholením, a její popis nenahrazuje posouzení této meze, které patří do Kapitola 4. Projekt (36) se od tohoto stavu posunul dál; kam se posunul a proč, je předmětem práce následující, a zde to záměrně není rozvedeno.

4 Zjištění a diskuse

5 Závěr

Seznam zdrojů

1. GITHUB. *GitHub Copilot code suggestions in your IDE* [online]. 2026 [vid. 2026-09-22]. Dostupné z: <https://docs.github.com/en/copilot/concepts/completions/code-suggestions>
2. GITHUB. *Asking GitHub Copilot questions in your IDE* [online]. 2026 [vid. 2026-09-22]. Dostupné z: <https://docs.github.com/en/copilot/how-tos/chat-with-copilot/chat-in-ide>
3. KHURANA, Sonam a Anusha VADDI. ChatGPT From the Perspective of an Academic Oral and Maxillofacial Radiologist. *Cureus* [online]. 2023, **15**(6). Dostupné z: doi:10.7759/cureus.40053. Obrázek 4. Screenshot z bezplatné verze ChatGPT, převzato jako ilustrace
4. GITHUB. *Use GitHub Copilot agents* [online]. 2026 [vid. 2026-09-22]. Dostupné z: <https://docs.github.com/en/copilot/how-tos/use-copilot-agents>
5. OPENAI. *Introducing Codex* [online]. 2025 [vid. 2026-09-22]. Dostupné z: <https://openai.com/index/introducing-codex/>
6. OPENAI. *Introducing the Codex app* [online]. 2026 [vid. 2026-09-22]. Dostupné z: <https://openai.com/index/introducing-the-codex-app/>
7. HILLEBRANDT, Finn. *How Many People Use AI? Facts & Figures 2026* [online]. 2026 [vid. 2026-09-22]. Dostupné z: <https://www.gradually.ai/en/how-many-people-use-ai/>. Published 2026-08-23
8. MARIUS, Patrik. *DarkFactory revize d576ec8f* [online]. 2026 [vid. 2026-09-26]. Dostupné z: <https://github.com/marius-patrik/DarkFactory/tree/d576ec8fdb78a654bfff9d0da165aa81a97b673>. Poslední revize, v níž ještě pipeline volá produkční harneysy
9. MERRIAM-WEBSTER. *Agentic: Definition & Meaning* [online]. 2026 [vid. 2026-09-26]. Dostupné z: <https://www.merriam-webster.com/dictionary/agentic>. Původ slova: agent + -ic, poprvé doloženo 1966
10. TRIVEDI, Vivek. *The Anatomy of an Agent Harness* [online]. 2026 [vid. 2026-09-27]. Dostupné z: <https://www.langchain.com/blog/the-anatomy-of-an-agent-harness>. LangChain, 10. března 2026
11. VASWANI, Ashish, Noam SHAZEER, Niki PARMAR, Jakob USZKOREIT, Llion JONES, Aidan N. GOMEZ, Łukasz KAISER a Illia POLOSUKHIN. Attention Is All You Need. *ar-*

- Xiv preprint arXiv:1706.03762 [online]. 2017. Dostupné z: <https://arxiv.org/abs/1706.03762>
12. MIKOLOV, Tomas, Wen-tau YIH a Geoffrey ZWEIG. Linguistic Regularities in Continuous Space Word Representations. In: *Proceedings of the 2013 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies* [online]. 2013, s. 746–751. Dostupné z: <https://aclanthology.org/N13-1090/>
 13. YAO, Shunyu, Jeffrey ZHAO, Dian YU, Nan DU, Izhak SHAFRAN, Karthik NARASIMHAN a Yuan CAO. ReAct: Synergizing Reasoning and Acting in Language Models. *arXiv preprint arXiv:2210.03629* [online]. 2022. Dostupné z: <https://arxiv.org/abs/2210.03629>
 14. ANTHROPIC. *Building effective agents* [online]. 2024 [vid. 2026-09-23]. Dostupné z: <https://www.anthropic.com/engineering/building-effective-agents>
 15. AGENT SKILLS. *Agent Skills: an open format for extending AI agents* [online]. 2025 [vid. 2026-09-22]. Dostupné z: <https://agentskills.io/home>
 16. OPENAI. *Lifecycle / OpenAI Agents SDK* [online]. 2026 [vid. 2026-09-22]. Dostupné z: <https://openai.github.io/openai-agents-python/ref/lifecycle/>
 17. MODEL CONTEXT PROTOCOL. *Model Context Protocol 2026-07-28 specification: server features* [online]. 2026 [vid. 2026-09-22]. Dostupné z: <https://modelcontextprotocol.io/specification/2026-07-28/server>
 18. AGENTIC AI FOUNDATION. *AGENTS.md* [online]. 2026 [vid. 2026-09-23]. Dostupné z: <https://agents.md/>
 19. ANTHROPIC. *Effective context engineering for AI agents* [online]. 2025 [vid. 2026-09-22]. Dostupné z: <https://www.anthropic.com/engineering/effective-context-engineering-for-ai-agents>
 20. LIU, Nelson F., Kevin LIN, John HEWITT, Ashwin PARANJAPE, Michele BEVILACQUA, Fabio PETRONI a Percy LIANG. Lost in the Middle: How Language Models Use Long Contexts. *Transactions of the Association for Computational Linguistics* [online]. 2024, **12**, 157–173. Dostupné z: <https://arxiv.org/abs/2307.03172>
 21. WILLISON, Simon. *What is agentic engineering?* [online]. 2026 [vid. 2026-09-26]. Dostupné z: <https://simonwillison.net/guides/agentic-engineering-patterns/what-is-agentic-engineering>. Kapitola průvodce Agentic Engineering Patterns

22. ALENEZI, Mamdouh. Educating the Agentic Engineer: Curricula, Collaboration, and Continuous Learning in the AI Era. *arXiv preprint arXiv:2607.29610* [online]. 2026 [vid. 2026-09-26]. Dostupné z: <https://arxiv.org/abs/2607.29610>
23. OPENAI. *Prompt engineering* [online]. 2026 [vid. 2026-09-22]. Dostupné z: <https://platform.openai.com/docs/guides/prompt-engineering>
24. ANTHROPIC. *Harness design for long-running application development* [online]. 2026 [vid. 2026-09-21]. Dostupné z: <https://www.anthropic.com/engineering/harness-design-long-running-apps>
25. OPENAI. *Sandbox agents: Concepts | OpenAI Agents SDK* [online]. 2026 [vid. 2026-09-22]. Dostupné z: <https://openai.github.io/openai-agents-js/guides/sandbox-agents/concepts/>
26. OPENAI. *Using Goals in Codex: Persistent Objectives for Long-Running Work* [online]. 2026 [vid. 2026-09-27]. Dostupné z: https://developers.openai.com/cookbook/examples/codex/using_goals_in_codex
27. OPENAI. *Agent orchestration | OpenAI Agents SDK* [online]. 2026 [vid. 2026-09-21]. Dostupné z: https://openai.github.io/openai-agents-python/multi_agent/
28. GALLARDO, Luis. *Beyond Cursor: My Experience with Claude Code and Sequential Thinking* [online]. 2025 [vid. 2026-09-28]. Dostupné z: <https://lgallardo.com/2025/07/09/beyond-cursor-claude-code-sequential-thinking/>. Obrázek s plánem, který Claude Code předkládá ke schválení. Převzatá ilustrace rozhraní, nikoli záznam běhu popsané pipeline
29. GOOGLE. *Antigravity CLI* [online]. 2026 [vid. 2026-09-27]. Dostupné z: <https://antigravity.google/product/antigravity-cli>. Sekce Subagents functionalities. Převzatá ilustrace rozhraní, nikoli záznam běhu
30. ANTHROPIC. *Orchestrate subagents at scale with dynamic workflows* [online]. 2026 [vid. 2026-09-27]. Dostupné z: <https://code.claude.com/docs/en/workflows>. Sekce Dynamic workflows. Převzatá ilustrace rozhraní, nikoli záznam běhu
31. HUNTLEY, Geoffrey. *Ralph Wiggum as a „software engineer“* [online]. 2025 [vid. 2026-09-27]. Dostupné z: <https://ghuntley.com/ralph/>. 14. července 2025. Původní text, který techniku pojmenoval
32. ANTHROPIC. *Keep Claude working toward a goal* [online]. 2026 [vid. 2026-09-27]. Dostupné z: <https://code.claude.com/docs/en/goal>

33. NATO. *Software Engineering: Report of a Conference Sponsored by the NATO Science Committee, Garmisch, Germany, 7–11 October 1968* [online]. Brussels: NATO, Scientific Affairs Division, 1969 [vid. 2026-09-27]. Dostupné z: <http://homepages.cs.ncl.ac.uk/brian.randell/NATO/nato1968.PDF>. 231 s. Zpráva o softwarové krizi; stažitelný přepis z roku 2001 má 136 stran, číslování citací se vztahuje k původnímu vydání
34. COMPUTER HISTORY MUSEUM. *Robert W. Bemer* [online]. [vid. 2026-09-27]. Dostupné z: <https://history.computer.org/bemer.html>. Životopis uvádí vynálezce pojmu software factory a jeho působení v General Electric
35. GITHUB. *About pull requests / GitHub Docs* [online]. 2026 [vid. 2026-09-21]. Dostupné z: <https://docs.github.com/en/pull-requests/get-started/about-pull-requests>
36. MARIUS, Patrik. *DarkFactory* [online]. 2026 [vid. 2026-09-27]. Dostupné z: <https://github.com/marius-patrik/DarkFactory>. Repozitář projektu, na němž praktická část staví

Seznam součástí textu

Obrázek 1	Doplňování kódu přímo v editoru: model navrhuje pokračování řádku, které člověk přijme nebo odmítne (1).....	5
Obrázek 2	Chatbot odpovídá textem a práci nechává člověku: místo aby snímek posoudil, přizná, že obrázky neumí, a je to uživatel, kdo musí dojít k závěru. Screenshot z bezplatné verze ChatGPT, převzato z (3).....	6
Obrázek 3	Odhad rozdělení uživatelů generativní AI podle typu (7).....	7
Obrázek 4	Ilustrace sémantického vztahu mezi vektorovými reprezentacemi slov <i>král</i> , <i>královna</i> , <i>muž</i> a <i>žena</i> (12).....	10
Obrázek 5	Vzor ReAct: myšlenka, akce a pozorování se střídají a každý z nich se připojí do kontextu, takže smyčka pokračuje na tom, co už model viděl. Končí odpovědí místo dalšího požadavku na nástroj (13).....	11
Obrázek 6	Plán, který model navrhne, než se začne psát kód: seznam kroků podle souborů, které se mění, a otázka, zda se má pokračovat. Znění plánu je tak oddělené od jeho provádění — je to rozhodnutí, které člověk schvaluje nebo odmítne, nikoli popis práce, která už běží. Screenshot z Claude Code, převzato z (28).....	14
Obrázek 7	Rozhraní Google Antigravity CLI, tedy harnessu agenta běžícího v terminálu: koordinátor definuje tři specializované subagenty a spouští je souběžně; každý běží vlastním kontextem (29).....	15
Obrázek 8	Postup práce dynamického workflow v Claude Code: vlevo fáze plánu se stavem, vpravo rozvinutá fáze <i>CodeReview</i> se 16 agenty, u každého model, spotřebované tokeny, počet nástrojů a doba běhu. Screenshot pochází z komunitního příspěvku; rozhraní i jeho chování popisuje dokumentace (30).....	16
Obrázek 9	Cíl, proti němuž agent postupuje, a jeho splnění: po dokončení dílčího kroku se stav porovná s cílem a běh v tomto případě končí, včetně doby, kterou zabral. Screenshot pochází z komunitního příspěvku; funkci popisuje dokumentace (26).....	17
Obrázek 10	Architektura: GitHub poskytuje události a vývojový stav, GitHub Actions výpočet, Docker odděluje běh a pythonovský runner převádí událost na agentní krok. Produkční harnessy zajišťují model, nástroje a pozorování (8).....	21
Obrázek 11	Průchod požadavku: implementace a plánování jsou odděleny lidskými bránami, implementace probíhá na větvi a review smyčka se opakuje, dokud nálezh nezmezí. Smyčka může skončit i bez verdiktu; zablokuje ji jen vyčerpaná kvóta (8).....	21

Tabulka 1	Předloha požadavku a nejstarší požadavek projektu, issue 727 z 20. září 2026. Předloha má šest polí, z nichž tři povinná, ale požadavek, který pipeline zpracovala jako první, předlohu nevyplnil: napsal volně, pod nadpisy <code>Problem</code> a <code>Contract</code> . Runner předává modelu titulek i tělo issue, takže právě to rozhoduje, co se do zadání dostane (8).....	23
-----------	--	----